

Preparation of Papers for IEEE Trans on Industrial Informatics (February 2022)1

Yulin Li, Chunyan Zhang, *Member, IEEE*, Qiuyang Fang, Xudong Zhao, *Senior Member, IEEE*, and Jianlei Zhang, *Mem-*

ber, IEEE

Abstract—phrases as this can result in a page being rejected by search engines. Ensure that your abstract reads well and is grammatically correct.

Index Terms—Enter key words or phrases in alphabetical order, separated by commas. For a list of suggested keywords, send a blank e-mail to keywords@ieee.org or visit http://www.ieee.org/organizations/pubs/ani_prod/keywrd98.txt

I. INTRODUCTION

THIS

II. SYSTEM MODEL AND PROBLEM FORMULATION

A. System Model

考虑一个由 N 个异构机器人组成的群组 $\mathcal{R} = \{1, \dots, N\}$ 被部署于未知环境中, 对 M 个任务点 $\mathcal{T} = \{1, \dots, M\}$ 开展协同信息采集。

1) *Task Characterization*: 假设环境中共有 K 种任务类型, 记为集合 $\mathcal{K} = \{1, \dots, K\}$, 并设 $\mathcal{Z} = \{1, \dots, z, \dots, Z\}$ 为所需能力维度集合。每种任务类型 $k \in \mathcal{K}$ 对各类观测或服务能力的潜在需求 $\mathcal{D}_k = [d_k^{(1)}, \dots, d_k^{(Z)}]$ 有价值 $\mathcal{V}_k$, 对于任务 $m \in \mathcal{T}$, 其具体需求向量记为 $\mathcal{L}_m = [l_m^{(1)}, \dots, l_m^{(Z)}]$ 。同时, 任务具有优先级列表 $\mathcal{P} = \{\rho_1, \dots, \rho_M\}$, 其中 ρ_m 表示任务 m 的优先级权重, 数值越大表示优先级越高。

2) *Robot Capability Characterization*: 每个机器人具备一定的可复用的信息采集服务能力 (机器人的机载传感器、通信模块及相关功能单元), 对于机器人 $n \in \mathcal{R}$, 其能力向量记为 $\mathcal{G}_n = [\eta_n^{(1)}, \dots, \eta_n^{(Z)}]$, 其中 $\eta_n^{(z)} \geq 0$ 表示机器人 n 在第 z 类能力上的可提供上限; 若机器人不具备该类能力, 则 $\eta_n^{(z)} = 0$ 。与后续数学记号保持一致, 本文仍采用“资源”向量的形式进行表记, 但其物理含义应理解为机器人可复用的观测与服务能力, 而非一次性消耗资源 Non-consumable Service Capability。

Yulin Li, Chunyan Zhang, Qiuyang Fang, and Jianlei Zhang are with the College of Artificial Intelligence, Nankai University, Tianjin 300381, China (e-mail: yulinlifight@mail.nankai.edu.cn; zhcy@nankai.edu.cn; qiuyangfang@mail.nankai.edu.cn; jianleizhang@nankai.edu.cn).

Xudong Zhao is with the Key Laboratory of Intelligent Control and Optimization for Industrial Equipment, Ministry of Education, Dalian University of Technology, Dalian 116024, China (e-mail: xdzhao-hit@gmail.com).

Corresponding author: Jianlei Zhang (e-mail: jianleizhang@nankai.edu.cn).

TABLE I: 主要符号说明

Notations	Descriptions
N, M	机器人数量与任务数量
Z, K	资源类型数量与任务类型数量
$\mathcal{R} = \{1, \dots, n, \dots, N\}$	机器人 (智能体) 集合
$\mathcal{T} = \{1, \dots, m, \dots, M\}$	任务集合
$\mathcal{Z} = \{1, \dots, z, \dots, Z\}$	资源维度集合
$\mathcal{K} = \{1, \dots, k, \dots, K\}$	任务类型集合
$\mathcal{P} = \{\rho_1, \dots, \rho_M\}$	任务优先级列表
$\mathcal{L}_m = [l_m^{(1)}, \dots, l_m^{(Z)}]$	任务 m 在环境中的资源需求向量
$\mathcal{D}_k = [d_k^{(1)}, \dots, d_k^{(Z)}]$	任务类型 k 的资源需求向量
$\mathcal{G}_n = [\eta_n^{(1)}, \dots, \eta_n^{(Z)}]$	机器人 n 的可复用资源能力向量
$\mathcal{B}_{n,m}^m = [b_{n,1}^m, \dots, b_{n,K}^m]$	机器人 n 对任务 m 所属类型的局部信念向量
$\hat{\mathcal{V}}_{n,m}$	机器人 n 基于局部信念估计的任务 m 期望基础价值
$\hat{\mathcal{L}}_{n,m} = [\hat{l}_{n,m}^{(1)}, \dots, \hat{l}_{n,m}^{(Z)}]$	机器人 n 基于局部信念估计的任务 m 期望资源需求向量
$\mathcal{SC} = \{\mathcal{A}_1, \dots, \mathcal{A}_M\}$	全局重叠联盟结构
$\mathcal{A}_m = \{A_m^{(1)}, \dots, A_m^{(N)}\}$	任务 m 的重叠联盟, 由各机器人分配给任务 m 的资源
$A_m^{(n)} = [a_{n,m}^{(1)}, \dots, a_{n,m}^{(Z)}]$	机器人 n 分配给任务 m 的资源向量
$\text{Mem}(\mathcal{A}_m)$	任务 m 的重叠联盟成员集
$\ A_m^{(n)}\ _1$	机器人 n 分配给任务 m 的资源总量, 即分配向量的 1-
$\varsigma_{n,m}$	基于机器人 n 信念估计的任务 m 资源完成度
$\mathcal{V}_k$	任务类型 k 的基础价值
U	全局总效用
$u_n^m(\mathcal{A}_m)$	机器人 n 参与任务 m 联盟获得的个体预期效用
$E_{n,m}^{\text{Cost}}$	机器人 n 参与任务 m 的综合消耗
$E_{n,m}^{\text{move}}$	机器人 n 从上一节点移动到任务 m 的移动消耗
$E_{n,m}^{\text{wait}}$	机器人 n 在任务 m 处的协同等待消耗
$E_{n,m}^{\text{exec}}$	机器人 n 执行任务 m 的实际执行消耗
ϖ, γ, β	移动消耗、等待消耗与执行消耗的单位系数
E_n^{max}	机器人 n 的最大可用能量预算
$AT_{n,m}$	机器人 n 抵达任务 m 的实际到达时刻
ST_m	任务 m 联盟的同步开始时刻
$FT_{n,m}$	机器人 n 完成任务 m 自身分工部分的时刻
FT_m	任务 m 联盟整体完成的时刻
$T_{n,m}^{\text{exec}}$	机器人 n 执行任务 m 分配部分的持续时间
$T_{n,m}^{\text{pre}}$	机器人 n 在任务 m 上同步开始前的等待时间
$T_{n,m}^{\text{post}}$	机器人 n 在任务 m 上同步结束前的等待时间

1) *Overlapping Coalition Model*: 由于单个机器人难以独立满足任务的信息采集需求, 通常需要多个机器人围绕任务点形成协同观测联盟。同一机器人为多个任务提供支持, 即形成重叠联盟结构。我们将执行同一任务的机器人归为同一联盟。对于任务 m , 其对应的联盟可表示为 $\mathcal{A}_m = \{A_m^{(1)}, \dots, A_m^{(N)}\}$, 其中 $A_m^{(n)} = [a_{n,m}^{(1)}, \dots, a_{n,m}^{(Z)}]$ 表示机器人 n 对任务 m 的能力投入向量。若机器人 n 未参与任务 m , 则 $A_m^{(n)} = \mathbf{0}$ 。因此, 任务 m 的联盟成员可定义为

$$\text{Mem}(\mathcal{A}_m) = \{n \in \mathcal{R} \mid A_m^{(n)} \neq \mathbf{0}\} \quad (1)$$




Fig. 1: Overall framework and workflow of the proposed BHTA.

2) Uncertainty and Belief Modeling: 在真实环境中, 机器人在观测前对于任务的真实需求 $\mathcal{L}_m$ 是未知的, 并且由于传感器噪声、观测范围限制以及机器人异构性, 不同机器人对同一任务往往会形成不同的初始判断。因此, 本文采用局部信念 (所属类型概率) 来描述机器人对未知任务类型的认知。该信念为真实的任务价值和需求提供判断, 也用于对任务价值与能力需求的估计。机器人 n 对任务 m 的局部信念向量定义为 $\mathcal{B}_n^m = [b_{n,1}^m, \dots, b_{n,K}^m]$, 并满足归一化条件 $\sum_{k \in \mathcal{K}} b_{n,k}^m = 1$ 。基于该信念分布, 机器人 n 对任务 m 的期望基础价值 $\hat{v}_{n,m}$ 评估为: $\hat{v}_{n,m} = \sum_{k \in \mathcal{K}} b_{n,k}^m \cdot v_k$, 对任务 m 期望需求估计为 $\hat{\mathcal{L}}_{n,m} = [\hat{l}_{n,m}^{(1)}, \dots, \hat{l}_{n,m}^{(Z)}]$ 。对于第 z 类需求, 其期望根据资源类型需求按局部信念加权求和得到: $\hat{l}_{n,m}^{(z)} = \sum_{k \in \mathcal{K}} b_{n,k}^m \cdot d_k^{(z)}$, $z \in \mathcal{Z}$ 。

B. Utility Function and Cost Model

对于机器人个体决策, 首先要评价任务对个体的效用, 因此首先定义任务的完成程度, 本文采用基于比例规则, 机器人获得的收益份额由其当前任务联盟的相对资源贡献决定。机器人 n 视角下任务 m 的完成度 $s_{n,m}$ 可由各有效资源维度上满足度的均值进行评估 (单项资源满足度上限为 1):

$$s_{n,m} = \frac{1}{Z_{n,m}^c} \sum_{z \in \mathcal{Z}_{n,m}^{>0}} \min \left(\frac{\sum_{i \in \text{Mem}(\mathcal{A}_m)} a_{i,m}^{(z)}}{\hat{l}_{n,m}^{(z)}}, 1 \right) \quad (2)$$

式中 $\mathcal{Z}_{n,m}^{>0} = \{z \mid \hat{l}_{n,m}^{(z)} > 0\}$ 为该任务期望需求量大于零的资源维度集合, $Z_{n,m}^c = |\mathcal{Z}_{n,m}^{>0}|$ 为对应的有效维度数量。机

器人 n 在任务 m 对应的重叠联盟 $\mathcal{A}_m$ 中的个体预期效用 $u_n^m(\mathcal{A}_m)$ 可表示为:

$$u_n^m(\mathcal{A}_m) = \frac{\|A_m^{(n)}\|_1}{\sum_{i \in \text{Mem}(\mathcal{A}_m)} \|A_m^{(i)}\|_1} \left(\hat{v}_{n,m} \cdot s_{n,m} \right) - E_{n,m}^{\text{Cost}} \quad (3)$$

其中, $(\hat{v}_{n,m} \cdot s_{n,m})$ 表示机器人 n 基于局部信念估计的任务完成收益; $\frac{\|A_m^{(n)}\|_1}{\sum_{i \in \text{Mem}(\mathcal{A}_m)} \|A_m^{(i)}\|_1}$ 代表在参与任务中的相对贡献比例。 $E_{n,m}^{\text{Cost}}$ 为执行该任务的综合成本, 定义如下

$$E_{n,m}^{\text{Cost}} = E_{n,m}^{\text{move}} + E_{n,m}^{\text{wait}} + E_{n,m}^{\text{exec}} \quad (4)$$

其中 $E_{n,m}^{\text{move}}$ 为移动消耗、 $E_{n,m}^{\text{wait}}$ 为协同等待消耗、 $E_{n,m}^{\text{exec}}$ 为执行消耗。详细定义如下:

1) 移动消耗: 考虑到机器人可参与多个任务, 其执行顺序会影响到达时间及最终总效用。为统一任务执行过程, 机器人构建任务序列需按任务相对重要性降序排列, 据此确定机器人到达各任务的时间。智能体从上一任务 m' 转移至当前任务 m 的能耗为 $E_{n,m}^{\text{move}}$:

$$E_{n,m}^{\text{move}} = \varpi \cdot \text{Dist}(m', m) \quad (5)$$

其中, $\text{Dist}(m', m)$ 表示任务 m' 与 m 之间的空间距离, ϖ 为单位距离的能量消耗系数。

2) 协同等待消耗 ($E_{n,m}^{\text{wait}}$): 在多机器人协同执行中, 联盟成员需要保持同步, 因此等待消耗由同步前等待和同步后等待两部分构成:

$$E_{n,m}^{\text{wait}} = \gamma \cdot (T_{n,m}^{\text{pre}} + T_{n,m}^{\text{post}}) \quad (6)$$




Fig. 2: Timing diagram of task m execution.

其中, 机器人 n 在任务 m 上同步开始前的等待时间定义为 $T_{n,m}^{pre} = ST_m - AT_{n,m}$, 表示其到达任务点后至联盟统一开始执行前的等待时间; 联盟的同步开始时刻由最晚到达成员决定, 即 $ST_m = \max_{i \in \text{Mem}(\mathcal{A}_m)} AT_{i,m}$ 。进一步地, 记 $T_{n,m}^{exec}$ 为机器人 n 执行任务 m 分配部分的持续时间, 则其完成自身分工的时刻为 $FT_{n,m} = ST_m + T_{n,m}^{exec}$; 联盟整体完成时刻为 $FT_m = \max_{i \in \text{Mem}(\mathcal{A}_m)} FT_{i,m}$ 。因此, 同步后等待时间可表示为 $T_{n,m}^{post} = FT_m - FT_{n,m}$, 即机器人 n 完成自身承担部分后至联盟整体结束前的等待时间。

3) 执行消耗 ($E_{n,m}^{exec}$): 在任务执行过程中, 机器人通过持续的信息采集与数据传输完成其承担的任务部分, 因此执行消耗与实际执行时长 $T_{n,m}^{exec}$ 成正比, 可表示为 $E_{n,m}^{exec} = \beta \cdot T_{n,m}^{exec}$ 。 β 表示单位时间的能量消耗系数。图 2 给出了联盟执行任务 m 时的时间轴示意, 其中蓝色、粉色和绿色区域分别表示移动、等待和执行阶段, 并标注了 $AT_{n,m}$ 、 ST_m 、 $FT_{n,m}$ 、 FT_m 、 $T_{n,m}^{pre}$ 、 $T_{n,m}^{exec}$ 与 $T_{n,m}^{post}$ 等关键量。

C. Problem Formulation

我们的目标是确定最优的重叠联盟划分 $\mathcal{SC}^*$, 使全局总效用最大化, 即所有机器人个体效用之和达到最大。其中, $a_{n,m}^{(z)}$ 表示机器人 n 分配给任务 m 的第 z 维能力投入量。相应的优化问题可表述为:

$$\max_{\mathcal{SC}} U = \sum_{m \in \mathcal{T}} \sum_{n \in \text{Mem}(\mathcal{A}_m)} u_n^m(\mathcal{A}_m) \quad (7)$$

$$\text{s.t.} \quad \sum_{m \in \mathcal{T}} E_{n,m}^{Cost} \leq E_n^{max}, \quad \forall n \in \mathcal{R} \quad (8)$$

$$0 \leq a_{n,m}^{(z)} \leq \eta_m^{(z)}, \quad \forall n \in \mathcal{R}, \forall m \in \mathcal{T}, \forall z \in \mathcal{Z} \quad (9)$$

其中, 约束 (8) 为能量上限约束, 智能体执行已分配任务序列时的总能耗不能超过其总能量; 约束 (9) 表示机器人分配给任务的实际能力投入不能超过其在对应维度上的可提供上限。由于物理资源不按跨任务累计扣减, 本文不对 $\sum_m a_{n,m}^{(z)}$ 施加累计资源约束, 而仅限制机器人对单任务的服务能力, 跨任务执行消耗则由约束 (8) 统一约束。

由于上述重叠联盟形成问题具有显著的组合优化特性, 直接求解最优联盟结构 $\mathcal{SC}^*$ 属于 NP-hard 问题, 通常难以在可接受的计算代价下获得全局最优解。为此, 本文设计了一种低复杂度的 OCF 启发式求解方法, 以在保证计算可行性的同时获得接近最优的联盟划分; 进一步地, 后续还将从博弈论视角对该优化过程进行分析, 以刻画多机器人联盟演化的内在决策机制。

III. GAMED-BASED OVERLAPPING COALITION FORMATION

A. 重叠联盟形成博弈模型 (Overlapping Coalition Formation Game Model)

重叠联盟形成 (Overlapping Coalition Formation, OCF) 博弈允许智能体同时加入多个联盟, 并在不同联盟间分配资源或能力, 这有别于传统联盟形成博弈 (Coalition Formation Game, CFG) 中“单个智能体同一时刻仅属于一个联盟”的设定。由于本文中机器人具备多维异构且可复用的服务能力, 能够将不同能力维度同时投入多个任务联盟; 同时, 前述优化问题包含整数分配变量、非线性效用函数及时间-能量耦合约束, 属于 NP-hard 问题, 集中式求解复杂度较高。因此, 本文将该问题建模为 OCF 博弈, 通过机器人基于偏好关系的分布式联盟选择与资源分配, 实现系统整体效用提升。

定义 1 (重叠联盟形成博弈模型): 本文提出的基于重叠联盟形成 (Overlapping Coalition Formation, OCF) 的多机器人协同任务分配问题可形式化为如下博弈:

$$\mathcal{G} = \langle \mathcal{R}, \mathcal{T}, \{\mathcal{X}_n\}_{n \in \mathcal{R}}, \mathcal{SC}, \mathcal{U} \rangle,$$

其中各要素定义如下:

- 博弈参与者 (Players $\mathcal{R}$): 机器人集合记为

$$\mathcal{R} = \{1, \dots, N\}.$$

每个机器人 $n \in \mathcal{R}$ 被视为具有自主决策能力的理性参与者。

- 任务集合 (Task Set $\mathcal{T}$): 待执行任务集合记为

$$\mathcal{T} = \{1, \dots, M\}.$$

对于任一任务 $m \in \mathcal{T}$, 所有向其投入能力的机器人共同构成对应的任务联盟。

- 可行策略空间 (Strategy Space $\mathcal{X}_n$): 机器人 n 的策略为其在所有任务上的能力分配方案, 记为

$$X_n = [A_1^{(n)}, \dots, A_M^{(n)}],$$

其中

$$A_m^{(n)} = [a_{n,m}^{(1)}, \dots, a_{n,m}^{(Z)}]$$

表示机器人 n 向任务 m 在各能力维度上的投入向量。于是, 机器人 n 的可行策略空间记为 $\mathcal{X}_n$, 其取值需满足能力上限、时间预算及能量约束等条件。

- 重叠联盟结构 (Overlapping Coalition Structure $\mathcal{SC}$): 给定全体机器人的策略剖面

$$\mathbf{X} = (X_1, \dots, X_N),$$

可诱导得到全局重叠联盟结构

$$\mathcal{SC} = \{\mathcal{A}_1, \dots, \mathcal{A}_M\},$$

其中任务 m 对应的联盟为

$$\mathcal{A}_m = \{A_m^{(1)}, \dots, A_m^{(N)}\}.$$

其成员集合定义为

$$\text{Mem}(\mathcal{A}_m) = \{n \in \mathcal{R} \mid A_m^{(n)} \neq \mathbf{0}\}.$$

由于机器人能够同时向多个任务分配不同能力维度, 允许存在

$$\text{Mem}(\mathcal{A}_m) \cap \text{Mem}(\mathcal{A}_{m'}) \neq \emptyset, \quad m \neq m',$$

这体现了 OCF 区别于传统不相交联盟形成博弈的核心特征。

- **联盟效用函数 (Coalition Utility Function U):** 定义联盟效用映射, 用于刻画各任务联盟在给定能力投入下产生的整体收益。对于任意任务 $m \in \mathcal{T}$, 其对应联盟 $\mathcal{A}_m$ 的总效用记为

$$U_m(\mathcal{A}_m) = U(\mathcal{A}_m).$$

该联盟总效用反映任务 m 在当前资源配置下的整体执行效果。进一步地, 联盟收益可按照成员的相对贡献分配给参与机器人, 因此机器人 n 在联盟 $\mathcal{A}_m$ 中获得的局部效用可记为

$$u_n^m(\mathcal{A}_m).$$

相应地, 机器人 n 在全局重叠联盟结构 $\mathcal{SC}$ 下的总效用可表示为其参与各任务联盟所得局部效用之和减去相应执行代价。

在上述 OCF 博弈框架下, 各机器人基于自身收益评估与系统状态感知, 自主调整其能力分配方案, 并逐步演化形成满足约束条件的稳定重叠联盟结构。

B. 演化规则与整体利他偏好

在重叠联盟形成 (OCF) 博弈中, 切换准则 (Switching Criterion) 定义了机器人决定从当前状态转移至另一状态 (如撤出某些任务并加入新任务) 的内在动机与触发条件。常见的切换准则包括帕累托准则 (Pareto Criteria) 与自私准则 (Selfish Criteria)。然而, 帕累托准则要求任何切换动作不能损害系统中任何其他成员的利益, 条件过于苛刻, 极易导致算法停滞; 而自私准则仅关注个体利益的最大化, 容易使多机器人集群陷入系统整体效用低下的局部最优解。

为了兼顾个体理性与集群整体的全局寻优能力, 本文在 OCF 博弈模型中引入了**整体利他偏好 (Holistic Altruistic Preference)** 作为机器人的核心切换准则。

1) Preference Relation: 在 OCF 博弈中, 机器人通过比较不同重叠联盟结构下的总净效用来形成偏好关系。

定义 2 (偏好关系): 对于任意机器人 $n \in \mathcal{R}$, 设 $\mathcal{SC}^P$ 和 $\mathcal{SC}^Q$ 为两种可行的重叠联盟结构。若

$$U_n(\mathcal{SC}^Q) > U_n(\mathcal{SC}^P),$$

则称机器人 n 更偏好联盟结构 $\mathcal{SC}^Q$ 于 $\mathcal{SC}^P$, 记为

$$\mathcal{SC}^Q \succ_n \mathcal{SC}^P.$$

若

$$U_n(\mathcal{SC}^Q) \geq U_n(\mathcal{SC}^P),$$

则记为

$$\mathcal{SC}^Q \succeq_n \mathcal{SC}^P.$$

因此, 机器人的联盟选择行为本质上是基于总净效用最大化的偏好驱动过程。

在上述一般偏好关系的基础上, 本文进一步采用整体利他偏好作为具体切换准则。

定义 3 (整体利他偏好): 对于任意机器人 $n \in \mathcal{R}$, 设其通过资源重分配调整决策向量 $\mathbf{X}_n$ 后, 系统由当前重叠联

盟结构 $\mathcal{SC}^P$ 演化为新的重叠联盟结构 $\mathcal{SC}^Q$ 。若机器人 n 偏好执行该切换, 即 $\mathcal{SC}^Q \succ_n \mathcal{SC}^P$, 则需满足

$$\mathcal{SC}^Q \succ_n \mathcal{SC}^P \iff \begin{cases} U_n(\mathcal{SC}^Q) > U_n(\mathcal{SC}^P), \\ U_n(\mathcal{SC}^Q) - U_n(\mathcal{SC}^P) \\ > \sum_{o \in \mathcal{R} \setminus \{n\}} (U_o(\mathcal{SC}^P) - U_o(\mathcal{SC}^Q)). \end{cases} \quad (10)$$

其中, $U_n(\mathcal{SC})$ 表示机器人 n 在全局联盟结构 $\mathcal{SC}$ 下的个体总净效用, 由其在各任务联盟中的个体收益累加得到:

$$U_n(\mathcal{SC}) = \sum_{m \in \mathcal{T}} u_n^m(\mathcal{A}_m) \quad (11)$$

式 (10) 表明, 整体利他偏好同时要求切换动作满足个体收益改进与系统收益改进两项条件。前一条件保证动作发起者 n 在切换后的个体总净效用得到提升, 从而保持博弈个体的基本理性; 后一条件要求该增益能够覆盖其余机器人因切换产生的总效用损失。对第二个不等式移项, 可得

$$\begin{aligned} U_n(\mathcal{SC}^Q) + \sum_{o \in \mathcal{R} \setminus \{n\}} U_o(\mathcal{SC}^Q) \\ > U_n(\mathcal{SC}^P) + \sum_{o \in \mathcal{R} \setminus \{n\}} U_o(\mathcal{SC}^P), \end{aligned} \quad (12)$$

进一步有

$$\sum_{r \in \mathcal{R}} U_r(\mathcal{SC}^Q) > \sum_{r \in \mathcal{R}} U_r(\mathcal{SC}^P). \quad (13)$$

因此, 只要某一切换动作被整体利他偏好准则接受, 系统的全局社会总效用 (Global Social Utility, GSU) 便严格增加。与要求所有成员均不受损的帕累托准则相比, 该偏好关系在保留个体理性的同时适度放宽了切换条件, 从而增强了机器人集群的全局寻优能力。

2) Switching Operation and Strategy: 定义 4 (单边切换与 o-profitable deviation): 设当前重叠联盟结构为

$$\mathcal{SC}^P = \{\mathcal{A}_1^P, \dots, \mathcal{A}_M^P\},$$

若机器人 n 将其第 z 维能力分量 $\eta_n^{(z)}$ 由联盟 $\mathcal{A}_i^P$ 切换至联盟 $\mathcal{A}_j^P$, 则有

$$\mathcal{A}_i^Q = \mathcal{A}_i^P \setminus \{\eta_n^{(z)}\}, \quad \mathcal{A}_j^Q = \mathcal{A}_j^P \cup \{\eta_n^{(z)}\}, \quad (14)$$

并生成新的重叠联盟结构

$$\mathcal{SC}^Q = \mathcal{SC}^P \setminus \{\mathcal{A}_i^P, \mathcal{A}_j^P\} \cup \{\mathcal{A}_i^Q, \mathcal{A}_j^Q\}. \quad (15)$$

上述单边切换操作在满足约束条件且

$$\mathcal{SC}^Q \succ_n \mathcal{SC}^P$$

时, 称为一个 o-profitable deviation。

3) Stable Overlapping Coalition Structure: 基于上述偏好关系与切换操作, 本文进一步给出稳定重叠联盟结构的定义。

定义 5 (o-stable 重叠联盟结构): 对于当前重叠联盟结构

$$\mathcal{SC}^P = \{\mathcal{A}_1^P, \dots, \mathcal{A}_M^P\},$$

若对于任意机器人 $n \in \mathcal{R}$, 均不存在满足约束条件的单边 o-profitable deviation, 则称 $\mathcal{SC}^P$ 为一个 o-stable 重叠联盟结构。

换言之, 在 o-stable 重叠联盟结构下, 任一机器人均无法通过单边 o-profitable deviation 获得更优的联盟结构, 因此系统在给定偏好关系与切换准则下达到局部稳定状态。

IV. ALGORITHM FOR OVERLAPPING COALITION FORMATION

基于前文构建的重叠联盟形成（OCF）博弈模型，本文提出一种信念驱动的启发式任务分配算法（BHTA）以实现分布式求解。主要包括三个阶段：启发式联盟搜索阶段，任务执行与协同观测阶段；信息融合与信念更新阶段。具体过程见算法 1。同时图 1 从宏观上展示了该方法的闭环架构；

1) **启发式联盟搜索阶段**：具体而言，在第 t 轮中，在当前局部信念给定的条件下，系统调用 Algorithm 2 执行基于模拟退火的启发式联盟搜索，以生成本轮高质量的重叠联盟结构；

2) **物理执行与协同观测阶段**：机器人依据当前联盟结构进行任务部署与资源投入，并在执行过程中获取局部观测信息；

3) **信息融合与信念更新阶段**：系统调用 Algorithm 3 融合全网新增观测，并通过 Dirichlet 后验更新修正局部信念，为下一轮联盟求解提供新的任务价值与需求估计。

上述过程按轮次循环执行，直至达到终止条件，最终输出演化完成的重叠联盟结构与局部信念集合。

Algorithm 1 基于协同观测与信念更新的 BHTA 动态博弈框架

Require: 机器人集合 $\mathcal{R}$, 任务集合 $\mathcal{T}$, 任务类型集合 $\mathcal{K}$, 最大博弈轮次 T_{max} , 初始温度 T_0 , 降温系数 α , 最低温度阈值 T_{min}

Ensure: 演化完成的全局重叠联盟结构 $\mathcal{SC}^*$ 与最终局部信念集合 $\{\mathcal{B}_n^m(T_{max})\}_{n,m}$

```

1: Initialization:
2: 初始化博弈轮次  $t \leftarrow 1$ , 系统全局温度  $Temp \leftarrow T_0$ , 初始空联盟结构  $\mathcal{SC}(0) \leftarrow \emptyset$ ;
3: for  $\forall n \in \mathcal{R}$  and  $\forall m \in \mathcal{T}$  do
4:   初始化局部信念向量  $\mathcal{B}_n^m(0)$  (无先验知识时采用均匀 Dirichlet 先验对应的均匀初始化);
5:   初始化局部观测统计矩阵  $\mathcal{O}_n(0) \leftarrow \mathbf{0}_{M \times K}$ ;
6: end for
7: while  $t \leq T_{max}$  do
8:   {Phase 1: 重叠联盟形成博弈}
9:   继承上一轮精英解  $\mathcal{SC}(t-1)$  作为热启动基准, 结合当前温度  $Temp$  与局部信念集合  $\{\mathcal{B}_n^m(t)\}_{n,m}$ , 调用 Algorithm 2 求解本轮最优联盟结构  $\mathcal{SC}(t)$ ;
10:  {Phase 2: 物理执行与协同观测}
11:  机器人集群按  $\mathcal{SC}(t)$  部署至各任务节点投入资源, 并执行局部观测, 获取新增任务类型标签;
12:  {Phase 3: 信息融合与信念更新}
13:  调用 Algorithm 3 融合全网观测标签, 更新各机器人的局部观测统计与后验局部信念  $\{\mathcal{B}_n^m(t+1)\}_{n,m}$ ;
14:  更新温度  $Temp \leftarrow \max(\alpha \cdot Temp, T_{min})$  及轮次  $t \leftarrow t+1$ ;
15: end while
16: Output: 达到最大博弈轮次, 输出最终联盟结构  $\mathcal{SC}(T_{max})$  与局部信念集合  $\{\mathcal{B}_n^m(T_{max})\}_{n,m}$ 

```

A. 基于模拟退火的启发式联盟形成

现有重叠联盟形成研究多采用无导向最佳响应或简单随机搜索策略，并进一步发展出偏好引力引导禁忌搜索

(PGG-TS) 等方法，以增强搜索导向并避免重复访问已搜索解。然而，在本文的 OCF 场景下，每个机器人需围绕多个任务同时进行多维资源分配，并满足时间与能量等耦合约束，导致联盟结构搜索空间急剧扩张，搜索过程易出现收敛缓慢和局部停滞。为此，本文在分布式联盟形成过程中引入模拟退火思想，并结合禁忌记忆机制构造启发式联盟形成策略。在每轮博弈中，机器人依据局部信念估计任务价值与需求，通过启发式评分和玻尔兹曼概率生成资源重分配选择；其中，高温阶段以受控概率接受次优移动以增强全局探索能力，低温阶段逐步转向对优势联盟结构的局部开发，而禁忌列表则用于避免循环回访和重复搜索。借助二者的协同作用，所提方法能够在保证求解可行性的同时，更快获得高质量的重叠联盟结构。具体步骤如下。

1) **启发式特征提取与综合评分**：在第 k 次迭代时，机器人 n 分配给任务 m 的能力向量表示为 $\mathcal{A}_n^{(n)}(k) = [a_{n,m}^{(1)}(k), \dots, a_{n,m}^{(z)}(k), \dots, a_{n,m}^{(Z)}(k)]$ ，相应全局重叠联盟结构记为 $\mathcal{SC}^{(k)} = \{\mathcal{A}_1^{(k)}, \dots, \mathcal{A}_M^{(k)}\}$ 。结合前文由局部信念 $\mathcal{B}_n^m$ 诱导的期望需求估计 $\hat{\mathcal{L}}_{n,m}$ ，任务 m 在第 z 类能力上的估计缺口定义为

$$Gap_{n,m}^{(z)}(k) = \max \left(\hat{l}_{n,m}^{(z)} - \sum_{i \in \text{Mem}(\mathcal{A}_m^{(k)})} a_{i,m}^{(z)}(k), 0 \right).$$

为指导下一步分配，系统需要计算机器人 n 的第 z 类能力在各任务上的选择概率向量，记为 $P_n^{(z)}(k) = [p_{n,1}^{(z)}(k), \dots, p_{n,m}^{(z)}(k), \dots, p_{n,M}^{(z)}(k)]$ 。

为了使不同量纲的物理指标在决策中可比较，策略首先对决定任务吸引力的四个关键特征进行归一化处理。为书写简便，下述特征仅对随搜索状态变化的量显式保留迭代标记 (k) ：

具体而言，任务优先级特征 Pri_m 用于反映任务 m 的紧急与重要程度，定义为 $Pri_m = \rho_m / \rho_{max}$ ；资源紧缺度特征 $Dem_{n,m}^{(z)}(k)$ 用于刻画机器人 n 视角下任务 m 在第 z 类能力上的当前估计缺口，定义为 $Dem_{n,m}^{(z)}(k) = Gap_{n,m}^{(z)}(k) / Gap_{n,max}^{(z)}(k)$ ，其中 $Gap_{n,max}^{(z)}(k) = \max_{j \in \mathcal{T}} Gap_{n,j}^{(z)}(k)$ ；机器人供给特征 $Sup_n^{(z)}(k)$ 用于表征机器人 n 在第 z 类能力上的可调度能力上限，定义为 $Sup_n^{(z)}(k) = \eta_n^{(z)} / \eta_{max}^{(z)}$ ；空间距离特征 $Dis_{n,m}(k)$ 则反映机器人 n 从当前位置或前序任务位置转移至任务 m 的有效移动代价，定义为 $Dis_{n,m}(k) = Dist_{n,m}(k) / Dist_{max}$ 。

基于上述特征，定义机器人 n 在第 k 次迭代时对任务 m 投入资源 z 的启发式综合得分 $S_{n,m}^{(z)}(k)$ 为：

$$S_{n,m}^{(z)}(k) = \frac{Pri_m^2 \cdot Dem_{n,m}^{(z)}(k) \cdot Sup_n^{(z)}(k)}{Dis_{n,m}(k) + \epsilon} \quad (16)$$

式中， ϵ 为防止分母为零的微小正数。该评分机制对高优先级任务赋予更高权重，并优先选择估计缺口较大、可调度能力较强且移动代价较低的任务。

2) **玻尔兹曼概率选择**：为保证分配方案的物理可行性，策略中引入了硬约束掩码（Masking）机制：当机器人自身缺乏第 z 类能力（即 $Sup_n^{(z)} \leq \epsilon$ ），或任务在当前信念估计下对该能力已无缺口（即 $Dem_{n,m}^{(z)}(k) \leq \epsilon$ ）时，其对应的综合得分被强制置零。设有效候选任务集合为 $\Omega_n^{(z)}(k) = \{j \in \mathcal{T} \mid S_{n,j}^{(z)}(k) > \epsilon\}$ 。

最终，利用玻尔兹曼分布将启发式得分转化为当前迭代下的选择概率。该资源-任务匹配策略使机器人倾向于将能力分配给潜在收益更高的任务，从而加速联盟结构搜索：

$$p_{n,m}^{(z)}(k) = \begin{cases} \frac{\exp(S_{n,m}^{(z)}(k)/T(k))}{\sum_{j \in \Omega_n^{(z)}(k)} \exp(S_{n,j}^{(z)}(k)/T(k))}, & \text{if } m \in \Omega_n^{(z)}(k) \\ 0, & \text{otherwise} \end{cases} \quad (17)$$

式中, $T(k)$ 为模拟退火过程在第 k 次迭代时的系统温度。高温阶段保留较强的探索性, 而降温后选择概率逐步向高分任务集中, 从而实现由全局搜索向局部收敛的平滑过渡。为避免指数运算中的数值溢出, 实际计算时对指数项采用减去最大值的平移处理 (Shifted Softmax)。

在获得资源-任务选择概率后, 算法进一步结合随机资源撤出、候选联盟结构生成、Metropolis 概率接受以及禁忌表记忆机制执行单轮内部搜索。该过程在固定当前局部信念的条件下迭代优化联盟结构, 并输出本轮搜索得到的精英解, 具体如 Algorithm 2 所示。

B. 信念融合与局部信念更新

在完成当前轮联盟执行后, 机器人集群会在任务节点上获得新的局部观测标签。由于单个机器人视角有限且观测结果可能受噪声影响, 系统需要通过周期性通信将新增观测进行融合, 并据此更新各机器人对任务类型的局部信念。该过程发生在轮次之间, 而非上一小节的单轮内部搜索之内, 因此与“固定当前信念进行联盟搜索”的设置并不矛盾。

设机器人 $n \in \mathcal{R}$ 单次正确识别任务真实类型的概率为 $d_n \in (0, 1)$, 用于刻画其观测可靠度。每次局部观测都会输出一个任务类型标签; 受环境干扰和识别误差影响, 该标签以概率 $1 - d_n$ 偏离真实类型。令 $o_{n,m}^{(k)}(t)$ 表示在第 t 轮迭代结束时, 机器人 n 累计将任务 $m \in \mathcal{T}$ 判定为类型 $k \in \mathcal{K}$ 的观测次数。

在第 $t + 1$ 轮中, 系统通过离线或周期性通信融合全网新增的观测标签。设 $\delta_{n',m}^{(k)}(t+1)$ 为机器人 n' 在本轮新增的、将任务 m 判定为类型 k 的观测次数, 则全局融合后的累计观测记录更新为:

$$o_{n,m}^{(k)}(t+1) = o_{n,m}^{(k)}(t) + \sum_{n' \in \mathcal{R}} \delta_{n',m}^{(k)}(t+1), \quad \forall m \in \mathcal{T}, \forall k \in \mathcal{K} \quad (18)$$

为表征任务类型概率向量的不确定性, 本文对局部信念 $\mathcal{B}_n^m$ 采用均匀 Dirichlet 先验 $\text{Dir}(\alpha_0, \dots, \alpha_0)$, 其中 $\alpha_0 > 0$ 为公共伪计数参数。由于单次观测输出为离散类型标签, 融合后的类型计数满足多项计数统计 (multinomial count statistics), 因此其后验分布可写为:

$$\mathcal{B}_n^m(t+1) \sim \text{Dir}(\alpha_0 + o_{n,m}^{(1)}(t+1), \alpha_0 + o_{n,m}^{(2)}(t+1), \dots, \alpha_0 + o_{n,m}^{(K)}(t+1)) \quad (19)$$

依据该 Dirichlet 后验的期望性质, 机器人 n 判定任务 m 属于类型 k 的期望概率 (即信念向量 $\mathcal{B}_n^m = [b_{n,1}^m, \dots, b_{n,K}^m]$ 中的第 k 个元素) 可写为:

$$b_{n,k}^m(t+1) = \frac{\alpha_0 + o_{n,m}^{(k)}(t+1)}{\sum_{\kappa \in \mathcal{K}} (\alpha_0 + o_{n,m}^{(\kappa)}(t+1))} \quad (20)$$

在本文实现中, d_n 用于刻画机器人观测标签的可靠度背景, 而后验更新仍基于融合后的类型计数进行共轭更新。

Algorithm 2 BHTA internal simulated annealing search with global social utility and tabu enhancement

Require: 机器人集合 $\mathcal{R}$, 任务集合 $\mathcal{T}$, 初始温度 T_{max} , 终止温度 T_{min} , 降温系数 α , 资源撤出概率 p_{leave} , 禁忌表长度 L_{tabu} , 最大稳定迭代次数 K_{max}^{stable}

Ensure: 最优重叠联盟结构 $\mathcal{SC}^*$

```

1: Initialization:
2:  $k \leftarrow 1, k_{stable} \leftarrow 0, T(1) \leftarrow T_{max}, TabuList \leftarrow \emptyset;$ 
3: 生成初始重叠联盟结构  $\mathcal{SC}^{(1)}$ , 并记录当前最优全局社会效用  $U_{best} \leftarrow GSU(\mathcal{SC}^{(1)});$ 
4: 初始化精英缓存:  $\mathcal{SC}^{elite} \leftarrow \mathcal{SC}^{(1)}, U_{elite} \leftarrow U_{best};$ 
5: while  $k_{stable} \leq K_{max}^{stable}$  and  $T(k) \geq T_{min}$  do
6:    $\mathcal{SC}^{(k+1)} \leftarrow \mathcal{SC}^{(k)};$ 
7:   for each robot  $n \in \mathcal{R}$  do
8:     机器人  $n$  以概率  $p_{leave}$  随机撤出部分已分配资源  $\Delta a_{n,m}^{(z)};$ 
9:     依据玻尔兹曼概率公式 (17) 计算资源重分配的选择概率  $P_n^{(z)}(k);$ 
10:    生成候选重叠联盟结构  $\mathcal{SC}^{cand}$ , 并计算全局社会效用  $U_{cand};$ 
11:    计算全局效用差值  $\Delta E \leftarrow U_{cand} - GSU(\mathcal{SC}^{(k)});$ 
12:     $Accept \leftarrow \text{False};$  {判定是否接受状态跳转}
13:    if  $\mathcal{SC}^{cand} \in TabuList$  and  $U_{cand} > U_{best}$  then
14:       $Accept \leftarrow \text{True};$  {触发特赦准则 (Aspiration Criterion)}
15:    else if  $\mathcal{SC}^{cand} \notin TabuList$  and  $\text{rand}() \leq \exp(\Delta E/T(k))$  then
16:       $Accept \leftarrow \text{True};$  {满足 Metropolis 概率准则}
17:    end if
18:    if  $Accept == \text{True}$  then
19:       $\mathcal{SC}^{(k+1)} \leftarrow \mathcal{SC}^{cand};$ 
20:      将  $\mathcal{SC}^{cand}$  加入禁忌列表  $TabuList;$ 
21:      if  $U_{cand} > U_{best}$  then
22:         $U_{best} \leftarrow U_{cand};$ 
23:      end if
24:    end if
25:  end for
26:   $U_{curr} \leftarrow GSU(\mathcal{SC}^{(k+1)});$ 
27:  if  $U_{curr} > U_{elite}$  then
28:     $\mathcal{SC}^{elite} \leftarrow \mathcal{SC}^{(k+1)}, U_{elite} \leftarrow U_{curr};$ 
29:  end if
30:  if 解保持不变 ( $\mathcal{SC}^{(k+1)} == \mathcal{SC}^{(k)}$ ) 则  $k_{stable} \leftarrow k_{stable} + 1,$  否则  $k_{stable} \leftarrow 0;$ 
31:  退火降温  $T(k+1) \leftarrow \alpha \cdot T(k),$  并更新  $k \leftarrow k + 1;$ 
32: end while
33: Output: 输出精英缓存对应的最优联盟结构  $\mathcal{SC}^* \leftarrow \mathcal{SC}^{elite}$ 

```

通过上述机制，机器人集群能够随着博弈推进逐步形成更一致的任务类型认知，从而为后续联盟更新提供更稳定的需求估计依据。

上述信息融合与后验更新过程可概括为 Algorithm 3。

Algorithm 3 分布式信息融合与局部信念更新算法

Require: 历史局部观测统计集合 $\{O_n(t)\}_{n \in \mathcal{R}}$ ，全网新增观测标签增量 $\delta(t+1)$

Ensure: 更新后的局部观测统计集合 $\{O_n(t+1)\}_{n \in \mathcal{R}}$ ，后验局部信念集合 $\{B_n^m(t+1)\}_{n,m}$

```

1: {信息融合与后验信念更新}
2: for each robot  $n \in \mathcal{R}$  do
3:   获取全网集群在当前物理执行阶段产生的新增观测标签  $\delta(t+1)$ ;
4:   for each task  $m \in \mathcal{T}$  do
5:     % 融合全局观测标签
6:     根据公式 (18) 累加全网增量，更新局部观测矩阵  $O_n(t+1)$ ;
7:     % 狄利克雷后验分布期望计算
8:     for each type  $k \in \mathcal{K}$  do
9:       根据公式 (20) 计算任务类型的期望概率  $b_{n,k}^m(t+1)$ ;
10:    end for
11:    重组生成新的局部信念向量  $B_n^m(t+1)$ ;
12:  end for
13: end for
14: return  $\{O_n(t+1)\}_{n \in \mathcal{R}}, \{B_n^m(t+1)\}_{n,m}$ 
    
```

C. 稳定性与收敛性分析

1) 有限步终止性: 对于 Algorithm 2，若降温系数满足 $0 < \alpha < 1$ ，则温度序列 $T(k+1) = \alpha T(k)$ 单调递减，并将在有限步内降至阈值 T_{min} 以下；同时，算法还引入了最大稳定迭代次数 K_{max}^{stable} 作为附加终止条件。因此，无论是由温度衰减触发，还是由连续若干次迭代无状态变化触发，单轮内部搜索均会在有限步内终止。

2) 与 o -stable 联盟结构的关系: 前文定义 5 已给出了 o -stable 重叠联盟结构的判据，即不存在满足约束条件的单边 o -profitable deviation。在当前局部信念固定的单轮搜索中，Algorithm 2 通过启发式资源重分配、Metropolis 接受准则和禁忌记忆机制不断调整联盟结构，并以精英缓存保存当前轮的最优解。当算法终止且在允许的局部调整下无法进一步获得更高的当前轮全局社会效用时，所得输出可视为当前信念诱导收益函数下的局部稳定联盟结构。需要指出的是，由于外层框架中的局部信念会在各轮之间持续更新，整个 BHTA 产生的是一系列随认知演化而变化的局部稳定联盟结构，而非单一静态环境下的全局最优固定点。

3) Complexity analysis: 设 K_{SA} 表示 Algorithm 2 在单轮内部搜索中的实际迭代次数。对于每次迭代中的每个机器人，启发式评分与玻尔兹曼概率计算在 M 个任务和 Z 类能力上的复杂度约为 $\mathcal{O}(MZ)$ ；若将候选解的调度可行性验证与全局社会效用评估记为 C_{sched} ，则 Algorithm 2 的单轮复杂度可写为 $\mathcal{O}(K_{SA}N(MZ + C_{sched}))$ 。对于 Algorithm 3，全网观测融合与后验信念更新需要遍历机器人、任务及任务类型三个维度，其单轮复杂度为 $\mathcal{O}(NMK)$ 。因此，BHTA

在单个外层演化轮次中的总体复杂度可表示为

$$\mathcal{O}(K_{SA}N(MZ + C_{sched}) + NMK),$$

而经过 T_{max} 轮演化后的总复杂度为

$$\mathcal{O}(T_{max} [K_{SA}N(MZ + C_{sched}) + NMK]).$$

若将调度可行性检查近似视为与任务规模同阶，则上述复杂度可进一步近似为关于 N 、 M 、 Z 与 K 的多项式增长。

V. SIMULATION RESULTS

A. Setup

All simulations were conducted in a two-dimensional multi-robot task-allocation scenario. Unless otherwise specified, N agents and M tasks were randomly placed in a 100×100 m rectangular mission region. Each agent carried Z heterogeneous resource dimensions, and each task was associated with a demand vector, task value, and priority level generated from the parameter ranges in Table II. **中文对照:** 所有仿真实验均在二维多机器人任务分配场景中开展。除非另有说明， N 个智能体与 M 个任务随机分布在 100×100 m 的矩形任务区域内。每个智能体携带 Z 类异构资源，每个任务具有由表 II 参数范围生成的需求向量、任务价值和优先级。

During execution, agents selected tasks and allocated resources according to their remaining resources, task attributes, and local belief information. The overlapping coalition formation mechanism then coordinated the distributed decisions and produced the final task allocation. The main experiments evaluate BHTA under varying task-agent ratios, a representative single-case visualization, an ablation study on belief updating, and repeated trials over multiple random seeds. **中文对照:** 在任务执行过程中，智能体根据自身剩余资源、任务属性和局部信念信息选择任务并分配资源；重叠联盟形成机制进一步协调分布式决策并生成最终任务分配结果。主要实验包括不同任务-智能体比率下的对比、单次代表性案例可视化、信念更新机制消融实验以及多随机种子重复实验。

The simulations were run on a workstation with an Intel(R) Core(TM) i7-14700 CPU at 2.10 GHz, 32.0 GB memory, and MATLAB. **中文对照:** 仿真平台为 Intel(R) Core(TM) i7-14700 2.10 GHz CPU、32.0 GB 内存和 MATLAB。

B. Baselines, Fairness Settings, and Evaluation Metrics

1) Baselines: The proposed Belief-driven Heuristic Task Allocation (BHTA) algorithm was compared with three baselines: Non-overlapping Coalition Formation (NOCF) [1], Preference Gravity-guided Tabu Search (PGG-TS) [2], and JSE-OCF adapted from [3]. For JSE-OCF, the joining, switching, and exiting operations were retained and embedded into the same simulation model to form overlapping coalitions through heuristic rules. **中文对照:** 1) 基线设置: 本文将所提出的信念驱动启发式任务分配算法 BHTA 与三种基线方法进行比较: 非重叠联盟形成方法 NOCF [1]、偏好引力引导的禁忌搜索算法 PGG-TS [2]，以及基于文献 [3] 改编的 JSE-OCF。对于




Fig. 3: Performance comparison of four algorithms under varying numbers of tasks and agents. (a) Final coalition utility versus the number of tasks M with $N = 8$. (b) Completion rate versus the number of tasks M with $N = 8$. (c) Final coalition utility versus the number of agents N with $M = 10$. (d) Completion rate versus the number of agents N with $M = 10$.




Fig. 4: An example of multi-robot overlapping coalition formation under uncertainty. (a) Task execution route map. (b) Scheduling process of the proposed BHTA algorithm. (c) Differences between actual task demand and allocated resources. (d) Evolution of coalition utility, total coalition cost, and total completion value.




Fig. 5: Resource allocation matrix for the single visualization case.

JSE-OCF, 本文保留其加入、切换和退出三类操作，并将其嵌入统一仿真模型中，通过启发式规则形成重叠联盟。

2) *Fairness settings*: To improve comparability, all algorithms were evaluated under the same problem model, simulation framework, initial beliefs, observation budget,

stopping conditions, maximum iteration settings, resource-demand estimation rule, and random seeds where applicable. NOCF was constrained so that each agent could execute only one task and used a self-interested preference rule, whereas PGG-TS and JSE-OCF used the same




Fig. 6: Belief and expected task value visualization for the single visualization case.




Fig. 7: Convergence curves for the ablation study under all tested conditions.




Fig. 8: Endpoint scatter plot for the ablation study under all tested conditions.

altruistic preference criterion as the overlapping-coalition setting. 中文对照: 2) 公平性设置: 为提高可比性, 所有

算法均在相同的问题模型、仿真框架、初始信念、观测次数、停止条件、最大迭代设置、资源需求估计规则以及适

TABLE II: Main simulation parameters

Parameter	Value
Mission region Ω	100×100 m
Number of outer game rounds I_{out}	100
Maximum inner iterations per round $I_{\text{in}}^{\text{max}}$	80
Number of observations N_{obs}	50
Number of resource dimensions Z	6
Task value levels V_k	[500, 1000, 2000]
Upper bounds of task demand $\bar{d}_k$	[2, 5, 8]
Resource execution times τ_z	[50, 65, 50, 60, 35, 45] s
Agent speed v_n	2 m/s
Positive observation probability p_n^+	[0.75, 0.95]
Maximum energy budget E_n^{max}	[300, 350]
Motion fuel consumption coefficient ϖ	1 m^{-1}
Waiting fuel consumption coefficient γ	0.5
Execution cost coefficient β	1
Resource capacity range per dimension $\eta_n^{(z)}$	[0, 4]
Task priority range ρ_m	[1, 9]

用情况下相同随机种子下进行评估。NOCF 被限制为每个智能体只能执行一个任务，并采用自利型偏好；PGG-TS 与 JSE-OCF 则采用与重叠联盟设置一致的利他型偏好准则。

3) *Evaluation metrics*: The evaluation focuses on task completion, system utility, and algorithmic robustness. The completion rate (CR) measures the degree to which task demands are satisfied, while the final coalition utility U measures the net system benefit after coalition formation and resource allocation. Convergence curves and endpoint scatter plots are used to examine the evolution and variability of the algorithms across repeated trials. 中文对照：3) 评价指标：评价主要关注任务完成效果、系统效用和算法鲁棒性。任务完成率 CR 衡量任务需求的满足程度，最终联盟效用 U 衡量联盟形成与资源分配后的系统净收益。收敛曲线与终态散点图用于分析算法在重复实验中的演化过程和结果波动。

C. Overall Comparison

Table III and Fig. 3 compare the final coalition utility and CR of BHTA, NOCF, PGG-TS, and JSE-OCF under different values of N and M . Across all tested settings, BHTA consistently obtains the highest utility and CR among the four algorithms. 中文对照：表 III 与图 3 对比了 BHTA、NOCF、PGG-TS 和 JSE-OCF 在不同 N 与 M 设置下的最终联盟效用和任务完成率。在所有测试条件下，BHTA 在四种算法中均取得最高的效用和任务完成率。

When the number of tasks increases with $N = 8$ and $M \in [8, 20]$, the available task value increases, and the utility of all algorithms generally rises. At the same time, CR decreases as the fixed agent team becomes more heavily loaded. Under this setting, BHTA improves utility over the best competing baseline by 2.3%–5.9%. For example, at $M = 20$, BHTA reaches a utility of 14366.54 and a CR of 0.660, compared with 13631.63 and 0.637 for the best baseline. 中文对照：当智能体数量固定为 $N = 8$ 且任务数量 $M \in [8, 20]$ 增加时，系统可获得的任务价值增加，因此各算法效用整体上升；同时，固定智能体队伍的负载加重，任务完成率随之下降。在该设置下，BHTA 相比最佳竞争基线取得 2.3%–5.9% 的效用提升。例如在 $M = 20$ 时，

BHTA 的效用和任务完成率分别为 14366.54 与 0.660，而最佳基线为 13631.63 与 0.637。

When the number of agents increases with $M = 10$ and $N \in [4, 16]$, the additional resources improve task coverage and increase both utility and CR. BHTA maintains a 2.1%–6.7% utility gain over the strongest baseline. The largest relative gain in this group occurs at $N = 12$, where BHTA obtains 8656.21 compared with 8111.99 for the best baseline. When $N \geq 14$, CR becomes close to saturation, but BHTA still improves utility by producing more effective coalition structures. 中文对照：当任务数量固定为 $M = 10$ 且智能体数量 $N \in [4, 16]$ 增加时，额外资源提升了任务覆盖能力，使效用和任务完成率同步提高。BHTA 相比最强基线保持 2.1%–6.7% 的效用增益。在该组实验中，最大相对增益出现在 $N = 12$ ，BHTA 的效用为 8656.21，最佳基线为 8111.99。当 $N \geq 14$ 时，任务完成率已接近饱和，但 BHTA 仍能通过更有效的联盟结构提高系统效用。

D. Single-case Visualization

Fig. 4 illustrates one representative run with five robots and eight tasks under uncertainty. The route map shows the initial spatial distribution of tasks and robots, while the scheduling panel shows how BHTA forms overlapping coalitions during execution. For instance, robots 2 and 3 first cooperate on task 5; after that task is completed, robot 2 moves to task 6, whereas robot 3 proceeds to task 3. Fig. 4(c) and Fig. 5 further show the mismatch between actual task demands and allocated resources, where positive and negative deviations correspond to over-allocation and under-allocation, respectively. 中文对照：图 4 展示了不确定环境下 5 个机器人与 8 个任务的一次代表性运行。路径图给出了任务和机器人的初始空间分布，调度图展示了 BHTA 在执行过程中如何形成重叠联盟。例如，机器人 2 和机器人 3 首先协同执行任务 5；任务完成后，机器人 2 转向任务 6，而机器人 3 前往任务 3。图 4(c) 与图 5 进一步展示了实际任务需求与已分配资源之间的差异，其中正负偏差分别对应超额分配和分配不足。

Table IV reports the resulting schedule, carrying capacities, task demands, allocated resources, and completion degrees in descending priority order. The completion row indicates that T3 is fully completed, while T6 and T8 each reach 93.3% and T5 reaches 84.4%. Several tasks remain resource-limited, including T4 (64.6%), T2 (53.3%), T7 (51.9%), and T1 (50.0%). Thus, this case illustrates both effective high-value allocation and residual resource gaps under limited agent capacity. 中文对照：表 IV 按优先级降序列出了该案例的调度结果、携带资源、任务需求、已分配资源和完成度。完成度行显示，T3 完全完成，T6 和 T8 均达到 93.3%，T5 达到 84.4%。同时，若干任务仍受到资源限制，包括 T4 (64.6%)、T2 (53.3%)、T7 (51.9%) 和 T1 (50.0%)。因此，该案例同时展示了对高价值任务的有效分配以及智能体资源受限条件下仍存在的资源缺口。

As the game rounds progress in this representative case, the total completed value increases from 5551.59 to 7919.84, and the coalition utility increases from 4059.92 to 6519.07. Meanwhile, the global cost decreases from 1491.67

TABLE III: OVERALL PERFORMANCE COMPARISON OF FOUR ALGORITHMS

N	Varying number of agents N ($M = 10$)				M	Varying number of tasks M ($N = 8$)			
	NOCF	PGG-TS	JSE-OCF	BHTA		NOCF	PGG-TS	JSE-OCF	BHTA
4	3028.82(0.209)	5813.06(0.626)	5946.66(0.629)	6073.62(0.638)	8	5522.05(0.561)	7313.49(0.927)	7320.92(0.927)	7752.60(0.947)
6	4225.55(0.326)	7274.63(0.793)	6989.80(0.758)	7624.52(0.808)	10	5389.47(0.444)	8080.93(0.858)	8288.32(0.875)	8501.30(0.889)
8	5194.94(0.447)	7822.48(0.874)	7846.00(0.868)	8198.33(0.908)	12	6025.54(0.407)	9572.30(0.841)	9725.80(0.839)	10107.74(0.870)
10	6078.10(0.563)	8088.95(0.928)	8148.88(0.930)	8478.81(0.949)	14	6575.55(0.348)	11137.44(0.802)	11056.05(0.797)	11595.05(0.828)
12	6818.49(0.685)	8111.99(0.950)	8011.73(0.954)	8656.21(0.977)	16	6736.19(0.293)	12188.15(0.752)	11768.78(0.710)	12471.17(0.784)
14	7372.59(0.762)	8172.81(0.972)	8196.78(0.975)	8566.66(0.986)	18	6515.22(0.260)	12232.34(0.705)	11719.03(0.673)	12776.79(0.730)
16	7863.55(0.828)	8155.98(0.984)	8132.76(0.976)	8661.85(0.990)	20	6969.47(0.217)	13631.63(0.637)	13016.94(0.602)	14366.54(0.660)

Note: Left: varying agents N ($M = 10$). Right: varying tasks M ($N = 8$). Entries are formatted as $U(\text{CR})$, where U is final coalition utility and CR is completion rate. Best values are in bold.

TABLE IV: Agent-task schedule with resource allocations, carrying capacities, task demands, and completion degrees. Tasks are ordered by priority in descending order.

Agent	T4 (P8, V2000)		T5 (P7, V2000)		T3 (P6, V1000)		T6 (P5, V1000)		T2 (P4, V1000)		T8 (P3, V1000)		T7 (P2, V2000)		T1 (P1, V1000)	
	Start	End	Start	End	Start	End	Start	End	Start	End	Start	End	Start	End	Start	End
A1 [4, 0, 3, 1, 1, 3]	[4,0,3,0,1,3] 12.2	77.2	—	—	[4,0,3,0,0,3] 98.2	163.2	—	—	[4,0,3,0,1,3] 190.9	240.9	—	—	—	—	[4,0,3,0,0,3] 265.1	315.1
A2 [2, 4, 4, 3, 0, 2]	—	—	[2,4,4,3,0,2] 26.9	91.9	—	—	[2,4,4,3,0,2] 104.0	169.0	—	—	[2,4,4,3,0,2] 181.7	246.7	—	—	—	—
A3 [0, 1, 0, 2, 3, 2]	—	—	[0,1,0,0,3,2] 26.9	91.9	[0,1,0,2,3,0] 98.2	163.2	—	—	—	—	—	—	[0,1,0,2,3,2] 187.4	252.4	—	—
A4 [1, 0, 0, 4, 3, 0]	—	—	[1,0,0,4,3,0] 26.9	91.9	—	—	[1,0,0,4,3,0] 104.0	169.0	—	—	[1,0,0,4,3,0] 181.7	246.7	—	—	—	—
A5 [0, 2, 0, 3, 2, 2]	[0,2,0,3,2,2] 12.2	77.2	—	—	[0,2,0,3,2,0] 98.2	163.2	—	—	—	—	—	—	[0,2,0,3,2,2] 187.4	252.4	—	—
Demand	[5,5,6,7,4,5]		[5,5,6,7,4,5]		[3,3,2,5,5,2]		[3,3,2,5,5,2]		[3,3,2,5,5,2]		[3,3,2,5,5,2]		[5,5,6,7,4,5]		[3,3,2,5,5,2]	
Allocated	[4,2,3,3,3,5]		[3,5,4,7,6,4]		[4,3,3,5,5,3]		[3,4,4,7,3,2]		[4,0,3,0,1,3]		[3,4,4,7,3,2]		[0,3,0,5,5,4]		[4,0,3,0,0,3]	
Completion	64.6%		84.4%		100.0%		93.3%		53.3%		93.3%		51.9%		50.0%	

Note: Q denotes the carrying-capacity vector of each agent in the form $[R_1, R_2, R_3, R_4, R_5, R_6]$. For each agent, the first row gives the allocated resource vector for each executed task, and the second row gives the corresponding start and end times. *Demand* denotes the task demand vector. *Allocated* denotes the total allocated resource vector for each task across all participating agents.

to 1400.77. Fig. 6 shows that the task-type beliefs and expected task values become more stable as observations accumulate, which explains the improved allocation quality over the iterative process. 中文对照: 在该代表性案例中, 随着博弈轮次推进, 总完成价值由 5551.59 提升至 7919.84, 联盟效用由 4059.92 提升至 6519.07, 全局成本则由 1491.67 降至 1400.77。图 6 显示, 随着观测数据累积, 任务类型信念与期望任务价值逐渐稳定, 这解释了迭代过程中分配质量的提升。

E. Ablation Study

To isolate the contribution of the belief update mechanism, the complete BHTA was compared with a variant that removes belief updating and relies only on the initial beliefs for task allocation. The task number was fixed at $M = 15$, and the agent number was varied over $N \in \{4, 8, 12, 15\}$. Fig. 7 presents the convergence curves, and Fig. 8 presents the endpoint distributions of final utility and CR. 中文对照: 为分离信念更新机制的作用, 本文将完整 BHTA 与去除信念更新、仅依赖初始信念进行任务分配的变体进行比较。实验固定任务数量为 $M = 15$, 并令智能体数量在 $N \in \{4, 8, 12, 15\}$ 中变化。图 7 展示收敛曲线, 图 8 展示最终效用和任务完成率的状态分布。

TABLE V: Ablation Study Results: Utility and Completion Rate across Different Scenarios

Metric	Number of Agents (N)			
	4	8	12	15
U_{base}	4505 $\pm$ 1425	6208 $\pm$ 1756	6454 $\pm$ 1974	6372 $\pm$ 2029
U_{belief}	6221 $\pm$ 1669	9244 $\pm$ 1719	10515 $\pm$ 1769	10767 $\pm$ 2049
$\Delta U(\%)$	+38.1	+48.9	+62.9	+69.0
CR_{base}	0.419 $\pm$ 0.084	0.604 $\pm$ 0.100	0.657 $\pm$ 0.102	0.665 $\pm$ 0.107
CR_{belief}	0.464 $\pm$ 0.090	0.726 $\pm$ 0.078	0.841 $\pm$ 0.064	0.877 $\pm$ 0.065
ΔCR	+0.045	+0.121	+0.184	+0.213

Note: Results are presented as Mean $\pm$ Std over 51 seeds. Best results are highlighted in bold. U_{base} and CR_{base} denote the baseline algorithm without belief update, while U_{belief} and CR_{belief} represent the proposed BHTA. $\Delta U(\%)$ is the relative percentage improvement in utility, and ΔCR is the absolute difference in CR.

Table V quantifies the final performance gap between the two variants. As N increases, the utility improvement from belief updating grows from 38.1% at $N = 4$ to 69.0% at $N = 15$. The CR gain also increases from 0.045 to 0.213. At $N = 15$, BHTA achieves an average CR of 0.877, compared with 0.665 for the variant without belief updating. 中文对照: 表 V 量化了两个版本之间的最终性

能差异。随着 N 增加, 信念更新带来的效用提升从 $N = 4$ 时的 38.1% 增至 $N = 15$ 时的 69.0%; 任务完成率增益也从 0.045 增至 0.213。在 $N = 15$ 时, BHTA 的平均任务完成率为 0.877, 而无信念更新变体为 0.665。

These results indicate that stale or inaccurate initial beliefs can lead the robots to misestimate task types and resource requirements, thereby reducing both completed value and coalition utility. By continuously incorporating observations, BHTA updates the expected task values and demand estimates, which improves resource allocation especially when more agents participate in overlapping coalitions. **中文对照:** 这些结果表明, 过时或不准确的初始信念会使机器人误判任务类型和资源需求, 从而降低完成价值与联盟效用。BHTA 通过持续融合观测信息来更新期望任务价值与需求估计, 因此在更多智能体参与重叠联盟时能改善资源分配质量。

F. Convergence and Robustness Discussion

The convergence curves in Fig. 7 show that the belief-update version reaches higher utility levels than the no-update variant under the tested conditions. The endpoint scatter plots in Fig. 8, together with the mean and standard deviation over 51 seeds in Table V, further indicate that the performance gain is not limited to a single run. These observations support the use of belief updating as a recurring component of BHTA, while the statistical scope remains limited to the reported simulation settings. **中文对照:** 图 7 的收敛曲线显示, 在所测试条件下, 带信念更新版本能够达到高于无更新变体的效用水平。图 8 的终态散点图, 以及表 V 中 51 个随机种子的均值和标准差, 进一步表明该性能增益并非来自单次运行。这些观察结果支持将信念更新作为 BHTA 的常规组成部分, 但其统计范围仍限于本文报告的仿真设置。

VI. CONCLUSION

This paper investigated multi-robot task allocation under uncertain task types and heterogeneous reusable resources, and formulated the problem as an overlapping coalition formation framework. The proposed BHTA integrates local belief estimation, resource-contribution proportional allocation, and a holistic altruistic preference criterion into a dynamic coalition-formation process. Within this framework, robots update task-type beliefs from accumulated observations, estimate task values and resource demands from the current belief state, and search for high-quality overlapping coalition structures using a simulated-annealing-based heuristic with tabu enhancement. This design allows robots to participate in multiple task coalitions while keeping task allocation, resource feasibility, and energy-related execution costs within one utility-driven optimization model.

Simulation results under varying task-agent ratios show that BHTA consistently achieves higher final coalition utility and CR than NOCF, PGG-TS, and JSE-OCF in the tested settings. When the number of tasks increases with $N = 8$, BHTA improves utility over the strongest baseline by 2.3%–5.9%; when the number of agents increases with

$M = 10$, the utility gain remains 2.1%–6.7%. The representative single-case visualization further illustrates how overlapping coalitions evolve as beliefs and expected task values become more stable. The ablation study over 51 random seeds indicates that the belief update mechanism contributes substantially to both utility and CR, with the utility improvement increasing from 38.1% to 69.0% as N grows from 4 to 15. Future work will further examine larger-scale deployments, communication constraints, and real-time replanning under more dynamic task arrivals.

本文研究了在任务类型不确定且资源异构可复用的情境下的多机器人任务分配问题, 并将该问题构建为一个重叠联盟形成框架。所提出的 BHTA 算法将局部信念估计、资源贡献比例分配以及整体利他偏好准则整合到一个动态的联盟形成过程中。在该框架下, 机器人根据累积的观测数据更新对任务类型的信念, 基于当前的信念状态估算任务价值与资源需求, 并利用一种基于模拟退火且经禁忌搜索增强的启发式算法, 来搜寻高质量的重叠联盟结构。这种设计使得机器人能够同时参与多个任务联盟, 并将任务分配、资源可行性以及与能源相关的执行成本统一纳入到一个由效用驱动的优化模型之中。

在不同任务-智能体比例下的仿真结果表明, 在所测试的各类设定中, BHTA 算法在最终联盟效用和完成率 (CR) 方面均持续优于 NOCF、PGG-TS 和 JSE-OCF 等基准算法。当任务数量增加 (设定为 $N = 8$) 时, BHTA 算法相较于性能最佳的基准算法, 其效用提升幅度在 2.3% 至 5.9% 之间; 当智能体数量增加 (设定为 $M = 10$) 时, 其效用提升幅度仍保持在 2.1% 至 6.7% 之间。具有代表性的单案例可视化结果进一步展示了随着信念与预期任务价值趋于稳定, 重叠联盟结构是如何演化的。针对 51 个随机种子的消融实验研究表明, 信念更新机制对算法的效用和完成率均做出了实质性的贡献; 具体而言, 随着任务数量 N 从 4 增加至 15, 该机制带来的效用提升幅度也随之从 38.1% 增加到了 69.0%。未来的研究工作将进一步探索更大规模的部署场景、通信约束条件, 以及在任务动态到达情境下的实时重规划问题。

VII. REFERENCES

REFERENCES

- [1] X. Huo, H. Zhang, Z. Wang, C. Huang, and H. Yan, "A self-learning approach to heterogeneous multi-robot coalition formation under uncertainty," *IEEE Transactions on Automation Science and Engineering*, vol. 22, pp. 3445–3457, 2024.
- [2] N. Qi, Z. Huang, F. Zhou, Q. Shi, Q. Wu, and M. Xiao, "A task-driven sequential overlapping coalition formation game for resource allocation in heterogeneous uav networks," *IEEE Transactions on Mobile Computing*, vol. 22, no. 8, pp. 4439–4455, 2022.
- [3] S. Shi, C. Hu, D. Wang, Y. Zhu, and Z. Han, "Federated hd map updating through overlapping coalition formation game," *IEEE Transactions on Mobile Computing*, vol. 23, no. 2, pp. 1641–1654, 2023.